

Artem Kustikov

Principal Consultant, KI/DevOps/FullStack Softwareentwickler



[LinkedIn](#) | [GitHub](#) | [Credly](#) | [Microsoft Learning](#)

Wien ☐ Österreich

artem.kustikov@gmail.com ☐ +43 664 9310 6218

Principal Consultant und praxisorientierter Softwarearchitekt mit über 20 Jahren Erfahrung in der Konzeption und durchgängigen Umsetzung skalierbarer, cloud-nativer Systeme. Ich verantworte Architektur und Engineering für **KI/LLM-gestützte Anwendungen, verteilte ereignisgesteuerte Plattformen und Full-Stack-Webprodukte** und übersetze Geschäftsziele in widerstandsfähige, gut steuerbare Lösungen. Schwerpunkte: GenAI und agentische Systeme (LLM-Agenten, Evaluation und Observability, MCP), Solution- und Microservices-Architektur, Cloud-Infrastruktur (AWS, Azure, GCP), DevOps und Platform Engineering (Kubernetes, Terraform, CI/CD) sowie Echtzeit-Datenströme (Kafka, Flink). Ich verbinde technische Führung mit umfassender Liefererfahrung — Mentoring von Teams, Etablierung von Engineering-Best-Practices und die Bereitstellung skalierbarer Produktionssysteme.

Open-Source-Projekte

- **KateChat** — Selbst-gehostete Multi-Provider-LLM-Chat-Plattform (offene ChatGPT-Alternative). React/TypeScript-Frontend mit Node.js- und Rust-Backend; integriert AWS Bedrock, OpenAI und Yandex AI mit RAG (Docling), MCP-Tool-Servern, In-Browser-Python (Pyodide) und Bildgenerierung. GraphQL-API, WebSocket-Subscriptions, PostgreSQL/Redis.
- **docling.rs** — Performante Rust-Neuimplementierung von Python Docling, aufgenommen in das offizielle Docling-Projekt, die über 20 Dokumentformate (PDF, DOCX, PPTX, XLSX, HTML, EPUB, Bilder, Audio) in eine einheitliche `DoclingDocument`-Struktur für KI/RAG-Pipelines umwandelt. Reiner Rust-PDF-Parser mit ONNX-Layout/TableFormer/OCR-Stack und Whisper-ASR; 2–57× weniger Speicher und bis zu 46× schneller als Python, mit Node.js/TypeScript-Bindings. Erzeugt Markdown, docling-JSON und DocLang (`.doclx`) und enthält ein modulares RAG-Subsystem: Chunking, austauschbare Embedder und Vektordatenbanken, Hybrid-/Multi-Query-/HyDE-Retrieval sowie eine REST-API.

Erfahrung

Aug 2022 - Heute

Principal Consultant, KI/DevOps/FullStack Softwareentwickler

[Machine Learning Reply](#) Wien, Österreich

Stack: Node.js, React, Next.js • Java, Quarkus, Flyway • Python, PydanticAI • PostgreSQL, Cosmos DB, Redis • Apache Kafka, Flink, Confluent • Azure OpenAI, AWS Bedrock, Langfuse, MCP • Terraform, Kubernetes, Helm • AWS, Azure

Solution Architect/AI Engineer - Self-Service-Plattform für agentische KI

- End-to-End-Verantwortung für eine Self-Service-Plattform, auf der Fachanwender einen KI-Agenten im Chat beschreiben, ihn als bearbeitbaren visuellen Workflow zurückerhalten, veröffentlichen und mit echtem Traffic über ein gemeinsames Postfach, einbettbare Webformulare, Live-Telefonate (WebRTC mit kurzlebigen Ephemeral Tokens) und Cron-Zeitpläne betreiben; Agenten stützen sich auf Azure AI Foundry Vector Stores, antworten in der Sprache des Kunden, übergeben Ergebnisse an Salesforce und SAP und erreichen Kundensysteme über OAuth2-gesicherte MCP-Server mit verschlüsselt gespeicherten Tokens.
- Entwurf der Architektur: ein Next.js-Portal, zwei Python Azure Function Apps (Dispatcher und Executor auf PydanticAI über die Azure OpenAI Responses API) und Storage Queues als einzige Schnittstellen, verbunden durch einen gemeinsamen Workflow-JSON-Vertrag für ReactFlow-Canvas, Generierungs-Bot und Laufzeit — mit gestreamter Ausgabe, Retry-Klassifizierung und einem Redis-gestützten Human-in-the-Loop-Pause/Resume-Primitiv.
- Mandantenfähigkeit von Grund auf (domainbasierte Mandantenauflösung, Mandanten-Prädikat in jeder Abfrage, Buildbrechender Test für jede Abfrage ohne Mandanten-ID) und Auslieferung wahlweise als gemeinsames Portal mit kundenspezifischem Branding oder als Single-Tenant-Installation in der Azure-Subscription des Kunden; Terraform und GitHub Actions mit OIDC bauen die Plattform aus einer leeren Subscription auf, das Kunden-Onboarding besteht aus einem GitHub Environment und einer tfvars-Datei.

AI/ML Engineer - GenAI-Demonstratoren für Vertriebs- und Angebotsprozesse

- Aufbau einer LLM-as-a-Judge-Qualitätsschicht für kundenorientierte Chatbots: Jeder Gesprächsschritt wird in Langfuse erfasst und asynchron durch einen AWS Bedrock LLM-Judge in Kombination mit programmierten Metriken bewertet — 9 Live-Qualitätskennzahlen (Qualität, Kosten, Eskalationsrisiko), einsetzbar mit jedem Chatbot.

Solution Architect/FullStack - Plattform für Einteilung, Abrechnung und Verträge von Konzertveranstaltern

- Konzeption und Umsetzung einer mandantenfähigen Plattform für mehrere rechtlich getrennte Gesellschaften und Veranstaltungsformate: Ein Login unterstützt mehrere Rollen mit rollenspezifischen Funktionen; jede Abfrage wird über Zugriffsrechte je Mandant eingegrenzt, die an einen unterzeichneten Vertrag gekoppelt werden können.
- Modellierung wiederkehrender Dienstpläne, die Konzerte mit unveränderlichem Besetzungs-Snapshot erzeugen; Doppelbuchungen werden bereits in der Datenbank verhindert. Ergänzt um . ICS-Bestätigungs-E-Mails sowie PDF-Berichte zu Teilnehmern und Gagen.
- Durchgängig TypeScript auf Bun — GraphQL Yoga, Prisma/PostgreSQL, React/Redux/Mantine, Google- und Apple-OAuth — auf AWS ECS Fargate mit Terraform/Terragrunt und GitHub Actions; vollständig mit Claude Code entwickelt, von Anforderungen und Datenmodell bis zur Infrastruktur, als Fallstudie für AI-gestützte Entwicklung im Produktionsmaßstab.

Senior DevOps/FullStack - Web-Client für KI-Chatbot-System

- Entwicklung einer robusten und widerstandsfähigen CI/CD-Plattform mit integrierten Unit- und e2e-Tests (Playwright) und Feature-Umgebungen.
- Einführung nahtloser Benutzer-Authentifizierung und rollenbasierter Autorisierung gegen AWS Cognito.
- Unterstützung von kollaborativen Chats, Arbeitsbereichen, Dokumenten basierend auf WebSockets und WebRTC.

Senior Java Entwickler/DevOps - Plattform für einheitliches Fahrzeugdaten-Streaming

- Entwurf und Implementierung der Quarkus-Plattformdienste — Management API für Schemata, Datenbestellungen, Pipelines und Provisionierung sowie Deployment Service für Kafka-Topics, ACLs und Identity Pools auf Confluent — integriert mit Schema Registry und den Legacy-Fahrzeugdatendiensten des Kunden, mit Schema-Validierung bei der Aufnahme und korrigierter Kafka-Key-Auswahl für Reihenfolgegarantien.
- Verantwortung für die Flink-Schicht: Pipeline-Persistenz auf reaktivem Hibernate/Flyway mit automatischem Neustart fehlgeschlagener Jobs, byteidentisches Refactoring des zentralen Jobs, Redis-gestützter Regel-Cache, Upgrade auf Flink 2.2 sowie Migrationstool (Export, Rewrite, Import, wiederaufnehmbare Batches) und Cilium/Kyverno/ArgoCD/Helm-Codierung für den Umzug auf die neue Kubernetes-Plattform.
- Härtung und Skalierung der Azure-Edge: mTLS für Konsumenten, In-App-JWT-Validierung hinter einem Off/Shadow/Enforce-Schalter, Managed Identity statt SPN-Credentials sowie API-Management-Richtlinien mit gemeinsamem Redis-Token-Cache (99 % Trefferquote), die ~4,9 Mio. redundante Aufrufe pro 12 h beseitigten, die Kapazitätsgrenze von 31 Einheiten aufhoben und die Log-Analytics-Kosten um ~43 k EUR/Monat senkten.

DevOps Engineer/Senior Entwickler - Online Sales Forecasting Tool

- Refactoring bestehender Microservices in Java (Spring Boot), Python (FastAPI) und R (plumber) zur Skalierung in k8s; CI/CD-Framework auf Basis von GitHub Actions. Migration der Legacy-Infrastruktur von AWS (RDS und EC2 mit CloudFormation) auf einen privaten OpenShift-Cluster mit kontinuierlichem Deployment über Helm-Charts sowie Tekton-Trigger und -Pipelines.

Mai 2018 - Feb 2022

Systemarchitekt/Senior FullStack Softwareentwickler

Intetics Minsk, Belarus

Stack: Node.js (express, restify), ReactJS (TypeScript, redux, lerna, grpc-web), Go lang (GRPC, protobuf), Threedium, Rust, Docker, Kubernetes, Google Cloud Platform, MongoDB, PostgreSQL, Bigtable

Arbeit an großem B2B-Projekt in der Modebranche (#1 auf dem US-Markt), Integrationsaufgaben und Entwicklung einer benutzerdefinierten ETL-Engine (Extract, Transform, Load).

- Profiling und Refactoring von Node.js-Microservices; interaktive UI für das ETL-Tool mit [React Flow](#), [dagre](#) und GRPC.
 - Design und Implementierung von [Box.com](#)- und [Dropbox](#)-Konnektoren für die ETL-Engine (Go lang); Integration der excelize-Bibliothek in den XSL-Prozessor samt Behebung mehrerer [Probleme](#) im Bibliothekscode.
 - Integration von [Threedium](#) 3D-Modellen mit einer benutzerdefinierten React-Komponente.
-

Okt 2008 - Mai 2018

Systemarchitekt/Senior Softwareentwickler

EffectiveSoft Minsk, Belarus

Teilnahme an 20+ Projekten, darunter NLP- und Textmining-Tool Intellexer.

Stack: Node.js (express), React, Angular, Ext.js, AWS (EC2, ElasticBeanstalk, RDS, CloudFront), MySQL, Redis, MongoDB, .NET (C#/Managed C++), ASP.NET MVC, C++, COM, WinAPI, ActiveMQ, Python.

- **Crowdfunding-Software** — B2B-Plattform für lokale Unternehmen mit enger Integration des [Dwolla](#) Zahlungssystems: Architektur von Web-Client und Admin-App, CI-Setup (Bitbucket Pipelines, AWS CloudFormation) sowie ein Node.js-Background-Worker für Geldtransfers, Zinsberechnung und Finanzprüfung.
- **Medizin: DICOM/ECG-Parsing und -Analyse** — universeller ECG-Datenlader anstelle duplizierter Formatimplementierungen (Physionet, EFS, ISHNE, HL7), Canvas-basierter Web-Client zum Hochladen und Anzeigen von DICOM-Bildern (Zoom, WL-Transformation, interaktive Größenmessung) sowie ein Intranet-Tool zur Klinik-Personalsynchronisation mit ASP.NET MVC/SignalR.

Okt 2006 - Okt 2008

Senior Softwareentwickler

InventionMachine/[IHS Markit](#) Minsk, Belarus

Stack: .NET, C#, C++, ATL/MFC, JavaScript/AJAX, Java, ColdFusion

Jun 2004 - Sep 2006

Softwareentwickler

[SCAND](#) Minsk, Belarus

Stack: ASP 3.0 (VBScript), JavaScript/AJAX, C#, C++/boost/pthread, Java/Spring, MS SQL Server, Oracle

Dez 2002 - Jun 2004

Postgraduierter Student, Lehrer

Belarusian National Technical University Minsk, Belarus

Arbeit an Robotersimulation und analytischem Programmiersystem – komplexes rechnergestütztes Modellierungssystem zur Simulation realer Industrieroboter und ihrer Umgebung, Berechnung der Roboterkinematik, Kollisionsdetektion und analytische Programmierung. Außerdem als Dozent an der BNTU tätig und mehrere IT-bezogene Kurse unterrichtet: Grundlagen der Computernetzwerke, Mathematische Grundlagen der Roboterprogrammierung.

Fähigkeiten

- **JavaScript Full Stack:** (2002-heute) TypeScript, React/redux, Angular, Node.js, Express, Next.js, REST/GraphQL
- **DevOps:** (2015-heute) Docker, Terraform, Kubernetes, AWS, Azure, GCP, Gitlab
- **Python:** (2008-heute) Django, Flask, FastAPI, SQLAlchemy, Celery, NumPy, Pandas, nltk, Seaborn, Pytorch, scikit-learn
- **Java:** (2004-heute) Java 1.3/21, Struts/FOP/JSTL/POI, JBoss, Tomcat, Spring Framework, Spring Boot, Quarkus, Gradle
- Durchführung von 500+ technischen Interviews in JavaScript, DevOps, Java, .NET und Golang

Ausbildung

Belarusian National Technical University | Minsk, Belarus 1997-2002 | Informatik, Robotik

Zertifikate

- Jun 2026: [Microsoft AI & ML Engineering](#)
- Jan 2026: [AWS Generative AI Applications](#)
- Okt 2025: [Confluent Certified Developer for Apache Kafka](#)
- Mai 2024: HashiCorp Certified: [Terraform Associate \(003\)](#)
- Okt 2023: [AWS Certified Solutions Architect – Associate](#)
- Aug 2022: [DevOps on AWS](#)
- Apr 2017: [Machine Learning and Data Analysis from MIPT/Yandex](#)
- Sep 2016: [Microsoft Certified Solutions Associate: Web Applications](#)
- Feb 2013: Microsoft Certified Solutions Developer: Web Applications

Sprachen

Russisch (Muttersprache) • Englisch (verhandlungssicher), IELTS 6.5, CEFR B2 • Deutsch (beruflich), OIF Integrationsprüfung B1